Conv без bias:

$N_{weights} = C_{out} C_{in} K_h K_w$

MLP:

$N_{weights} = C_{in} C_{out} + C_{out}$

Conv1 $(3 \to 32, 7\times7)$: $N_1 = 32 \cdot 3 \cdot 7 \cdot 7 = 4704$

Conv2 $(32 \to 64, 5\times5)$: $N_2 = 64 \cdot 32 \cdot 5 \cdot 5 = 51200$

Conv3 $(64 \to 128, 3\times3)$: $N_3 = 128 \cdot 64 \cdot 3 \cdot 3 = 73728$

Conv4 $(128 \to 256, 1\times1)$: $N_4 = 256 \cdot 128 \cdot 1 \cdot 1 = 32768$

Conv5 $(256 \to 256, 3\times3)$: $N_5 = 256 \cdot 256 \cdot 3 \cdot 3 = 589824$

Conv6 $(256 \to 512, 1\times1)$: $N_6 = 512 \cdot 256 \cdot 1 \cdot 1 = 131072$

Linear1 $(512 \to 256, bias)$: $N_7 = 512 \cdot 256 + 256 = 131328$

Linear2 $(256 \to 100, bias)$: $N_8 = 256 \cdot 100 + 100 = 25700$

$N_{total} = \sum_i N_i = 1040324$

Сколько памяти в DRAM:

$W_{bytes} = N_{total} \cdot 4 = 4161296$ (байтов) ≈ 3.97 (Мб).

2. Вывод FLOPS:

Для Conv2d:

$$FLOPS = 2 B C_{out} H_{out} W_{out} C_{in} K_h K_w$$

$Conv_1$: $FLOPS_1 = 2 \cdot B \cdot 32 \cdot \frac{S}{2} \cdot \frac{S}{2} \cdot 3 \cdot 7 \cdot 7 = 2352 B S^2$

$Conv_2$: $FLOPS_2 = 2 \cdot B \cdot 64 \cdot \frac{S}{4} \cdot \frac{S}{4} \cdot 32 \cdot 5 \cdot 5 = 6400 B S^2$

$Conv_3$: $FLOPS_3 = 2 \cdot B \cdot 128 \cdot \frac{S}{8} \cdot \frac{S}{8} \cdot 64 \cdot 3 \cdot 3 = 2304 B S^2$

$Conv_4$: $FLOPS_4 = 2 \cdot B \cdot 256 \cdot \frac{S}{8} \cdot \frac{S}{8} \cdot 128 \cdot 1 \cdot 1 = 1024 B S^2$

$Conv_5$: $FLOPS_5 = 2 \cdot B \cdot 256 \cdot \frac{S}{16} \cdot \frac{S}{16} \cdot 256 \cdot 3 \cdot 3 = 4608 B S^2$

$Conv_6$: $FLOPS_6 = 2 \cdot B \cdot 512 \cdot \frac{S}{16} \cdot \frac{S}{16} \cdot 256 \cdot 1 \cdot 1 = 1024 B S^2$

GAP: $FLOPS_7 = B \cdot 512 \cdot \left(\frac{S}{16}\right)^2 = \underline{2} B S^2$ (мало!)

$Linear_1$: $FLOPS_8 = 2B \cdot 512 \cdot 256 = 262144 B$

$Linear_2$: $FLOPS_9 = 2B \cdot 256 \cdot 100 = 51200 B$ } копейки

$$\underline{FLOPS(S, B)} = \sum_i FLOPS_i = (17714 S^2 + 313344) B$$

3. Вывод $Memory(S, B)$

$Memory(S, B) = M_{stat} + M_{dyn}$

$M_{stat} = W_{bytes} = 4161296$ байт

$M_{dyn} = ?$

Пик памяти достигается в начале сети:

Вход X + выход Conv1 + MaxPool1 =

$= B \cdot 3 \cdot S \cdot S \cdot 4\delta + B \cdot 32 \cdot \frac{S}{2} \cdot \frac{S}{2} \cdot 4\delta + B \cdot 32 \cdot \frac{S}{4} \cdot \frac{S}{4} \cdot 4\delta =$

$= (3 + 8 + 2) BS^2 \cdot 4\delta = 52 BS^2 \delta$

$Memory(S, B) = 4161296 + 52 BS^2$ (байт)



4. Вывод потока данных BytesMoved(S, B)

Общий трафик состоит из трех частей: стат. веса, тензоров активации и тензоры MLP.

а) $Traffic_w = W_{bytes} = 416\,296$ б.

б) $Traffic_{spatial} = \sum b_i \cdot 4$ б.

$b = B \cdot C \cdot H \cdot W$

Вход X: $B \cdot 3 \cdot S \cdot S = 3BS^2$

Conv1: $B \cdot 32 \cdot \frac{S}{2} \cdot \frac{S}{2} = 8BS^2$

MaxPool1: $B \cdot 32 \cdot \frac{S}{4} \cdot \frac{S}{4} = 2BS^2$

Conv2: $B \cdot 64 \cdot \frac{S}{4} \cdot \frac{S}{4} = 4BS^2$

Conv3: $B \cdot 128 \cdot \frac{S}{8} \cdot \frac{S}{8} = 2BS^2$

Conv4: $B \cdot 256 \cdot \frac{S}{8} \cdot \frac{S}{8} = 4BS^2$

Conv5: $B \cdot 256 \cdot \frac{S}{16} \cdot \frac{S}{16} = BS^2$

Conv6: $B \cdot 512 \cdot \frac{S}{16} \cdot \frac{S}{16} = 2BS^2$

$Traffic_{spatial} = (3+8+2+4+2+4+1+2)BS^2 \cdot 4$ б. $=$

$= 26 \cdot 4BS^2$ б. $= 104BS^2$ б.

b) $\overline{Traffic}_{MLP} = (\overline{Traffic}_{GAP} + \overline{Traffic}_{Linear1} + \overline{Traffic}_{Linear2}) \cdot B =$

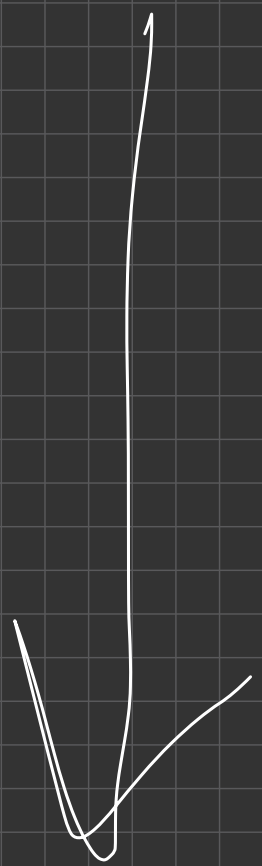
$= (512 \cdot 4\delta + 256 \cdot 4\delta + 100 \cdot 4\delta) B =$

$= 3472\, B\, \delta$

Libro:

$Bytes\,Moved(B, S) =$

$= 4162296\,\delta + B(1045^2 + 3472)\,\delta$



5. Модель времени выполнения $Latency(S, B, \theta)$

Учтем накладные расходы на вызовы ядер и сглаживание:

$$Latency(B, S, \theta) = t_{launch} + \left[\left(\frac{FLOPS(S,B)}{F_{peak}}\right)^p + \left(\frac{BytesMoved(S,B)}{B_{peak}}\right)^p\right]^{\frac{1}{p}},$$

где:

$\theta = \{t_{launch}, F_{peak}, B_{peak}, p\}$

t_{launch} – время запуска ядер и связи CPU ↔ GPU

F_{peak} – пиковая выч. производительность в FP32,

B_{peak} – пиковая пропускная способность памяти GPU,

p – параметр сглаживания.

Анализ режимов производительности

Критическая точка

$$I^* = \frac{F_{peak}}{B_{peak}} \approx 78 \frac{FLOP}{байт}$$

1. Launch-bound:

$S \leq 64$, $B \leq 2$

Время вычислений так мало, что время работы определяет t_{launch}, ≈ 0.5 мс.

2. Memory-bound:

$B = 1$, $S < 128$

Из-за размера батча синап. веса доминируют в нагрузке памяти, при этом сами вычисления мало, всё упирается в передачу ч/б.

$$I = \frac{FLOPS}{Bytes\,Moved} \approx 5 \dots 20 < I^*$$

3. Compute-Bound:

$B \geq 4$ V $S \geq 128$

Данные оптимизируются/считаются.

$$I = \frac{177\,Гц}{10\,Гц} \approx 170 \frac{FLOP}{байт} > I^*$$

6. Модель $Energy(S, B, \Theta)$

Снова есть статика и динамика:

$$Energy(S, B, \Theta) = P_{idle} Latency(S, B, \Theta) + e_{flop} FLOPS(S, B) + e_{byte} BytesMoved(S, B)$$

P_{idle} — стат. фоновая мощность в Вт;

e_{flop} — энергия на одну FLOP, в $\frac{Дж}{FLOP}$;

e_{byte} — энергия на чтение/запись 1 байта в $\frac{Дж}{байт}$.